

ChemAI: Predict the Cure

ML-pipeline для предсказания
биологической активности молекул



Предсказание IC50, CC50 и SI
на основе химических дескрипторов



Команда «Мехахарош»
Хакатон НИЯУ МИФИ 2026



Kaggle Score: **271.81367**



Команда:
Мехахарош



Участники:

- Костюченко Ярослав Андреевич
- Павлов Арсений Евгеньевич
- Шевченко Сергей Александрович
- Гиндуллина Регина Ильдаровна
- Болотный Дмитрий Олегович

Постановка задачи

Разработка лекарственных препаратов требует большого количества лабораторных экспериментов и значительных затрат времени.

Цель проекта — предсказать биологическую активность химических соединений с помощью методов машинного обучения.



IC50

Концентрация вещества, при которой подавляется 50% активности вируса.

↓ Меньше — лучше



CC50

Концентрация вещества, при которой токсичность наблюдается у 50% клеток.

↑ Больше — лучше



SI

Индекс селективности: отношение эффективности к токсичности препарата.

↑ Больше — лучше



ML-pipeline



Молекула



Химические дескрипторы



ML-модель



IC50 / CC50 / SI

Анализ данных

Исследуем структуру данных, распределения признаков и целевых переменных, а также выявляем потенциальные проблемы.

Train dataset



751 × 214

строк × колонок

Test dataset



250 × 211

строк × колонок

Признаки



210


химических
дескрипторов

Целевые переменные



3

IC50 / CC50 / SI



КЛЮЧЕВЫЕ ПОКАЗАТЕЛИ



Всего признаков

210



Признаков после
отбора (MI)

100



Константных признаков
удалено

18



Дубликаты строк
(по признакам) в train

121



Пропуски

Train — 24

Test — 12

КАЧЕСТВО ДАННЫХ



Шумы и выбросы
присутствуют
в данных



Дубликаты строк
обнаружены
(train: 121, test: 24)



Константные
признаки
18
удалены



Пропуски
Train — 24
Test — 12

ПРОСТРАНСТВО ПРИЗНАКОВ

210

исходных
дескрипторов



Mutual Information
Selection

Top-100


признаков
для каждой
target-переменной




Для каждой целевой переменной отбираются Top-100 признаков с наибольшей взаимной информацией с target (отдельно для IC50, CC50 и SI).

РАСПРЕДЕЛЕНИЯ ЗНАЧЕНИЙ ЦЕЛЕВЫХ ПЕРЕМЕННЫХ

Статистики рассчитаны для логарифмированных значений target-переменных ($\log_{10}$)



Минимум -2.71
1 квартиль -0.38
Медиана 0.37
Среднее 0.43
3 квартиль 1.20
Максимум 3.11



Минимум -2.27
1 квартиль -0.19
Медиана 0.29
Среднее 0.30
3 квартиль 0.72
Максимум 2.42




Минимум -2.60
1 квартиль 0.10
Медиана 0.62
Среднее 0.66
3 квартиль 1.12
Максимум 2.94



Целевые переменные имеют широкий диапазон значений и асимметричные распределения. Использование **логарифмирования** помогает снизить скошенность и улучшить **стабильность** моделей.

04 | Предобработка данных

Системный pipeline очистки и подготовки химических дескрипторов для устойчивого обучения ML-моделей.



КЛЮЧЕВЫЕ ПОКАЗАТЕЛИ ПРЕДОБРАБОТКИ



210

исходных дескрипторов



100

отобранных признаков для каждой target



5

фолдов кросс-валидации



Median Imputation
заполнение пропусков медианными значениями



$\log_{10}(x + 1)$
логарифмирование целевых переменных

ИТОГ ПОСЛЕ ПРЕДОБРАБОТКИ



640

чистых образцов в train



100

информативных признаков



3


целевые переменные
IC50 / CC50 / SI



Предобработка включает отбор наиболее информативных признаков и логарифмирование целевых переменных. Это позволяет **снизить влияние шума** и **скошенности**, **улучшить стабильность** моделей и их способность к обобщению.

05 | Архитектура моделей

Ансамбль из 5 базовых моделей и RidgeCV-meta-модель для получения финальных предсказаний.



СТРАТЕГИЯ ВАЛИДАЦИИ



5-Fold Cross-Validation
для целевых переменных IC50 и CC50



StratifiedKFold (5-fold)
для целевой переменной SI



RANDOM_STATE = 42
для воспроизводимости экспериментов

СОСТАВ АНСАМБЛЯ (5 моделей)

- ExtraTrees Regressor
- CatBoost Regressor
- XGBoost Regressor
- GradientBoosting Regressor
- LightGBM Regressor

КЛЮЧЕВОЙ ИНСАЙТ



Комбинация разнообразных моделей через RidgeCV позволяет получить более устойчивые и точные предсказания.



Использование ансамбля из 5 моделей и RidgeCV-meta-модели позволяет объединить сильные стороны алгоритмов и получить более устойчивые и точные предсказания на целевых переменных.

Результаты модели

Predictions-комбинация из 5 моделей с RidgeCV-meta-моделью

OOF RMSE (5-fold CV)

IC50 ↓



309.8008

RMSE

CC50 ↓



446.3594

RMSE

SI ↓



788.1076

RMSE

AVG ↓



514.7560

Mean RMSE

OOF RMSE ОТДЕЛЬНЫХ МОДЕЛЕЙ (5-fold CV)

IC50 ↓

CC50 ↓

SI ↓

Модель	RMSE	Модель	RMSE	Модель	RMSE
ExtraTrees	313.0446	ExtraTrees	450.0528	ExtraTrees	791.4148
CatBoost	327.5112	CatBoost	456.7136	LightGBM	837.3421
XGBoost	330.5780	XGBoost	465.7532	CatBoost	915.7337
LightGBM	337.0042	GradientBoosting	474.8070	XGBoost	924.0616
GradientBoosting	356.1595	LightGBM	476.3628	GradientBoosting	1018.2874

КЛЮЧЕВЫЕ ХАРАКТЕРИСТИКИ РЕШЕНИЯ



Отбор признаков

Top-100 (SelectFromModel на ExtraTrees)



Метод валидации

5-fold CV (IC50, CC50)

StratifiedKFold для SI



Трансформация таргетов

log10



Количество моделей

5



Meta-модель

RidgeCV



Используемые модели

ExtraTrees, CatBoost, XGBoost,

GradientBoosting, LightGBM



Predictions-комбинация моделей обеспечивает улучшение качества по всем целевым метрикам относительно лучших отдельных моделей.

07



ИТОГИ РАБОТЫ

В рамках проекта была решена задача предсказания биологической активности молекул на основе химических дескрипторов.



ЧТО БЫЛО СДЕЛАНО



Проведен анализ данных и обработано 210 химических дескрипторов



Выполнен отбор информативных признаков: Top-100 по важности (SelectFromModel на ExtraTrees)



Применена $\log_{10}$ -трансформация таргетов для стабилизации распределения



Использовано 5 моделей с 5-fold CV и подобраны оптимальные гиперпараметры



Сформированы финальные предсказания для трех таргетов

КАКИЕ РЕЗУЛЬТАТЫ ПОЛУЧЕНЫ



271.81367

Public Score на Kaggle Leaderboard

OOF РЕЗУЛЬТАТЫ (RMSE, 5-fold CV)

	ТАРГЕТ	RMSE (OOF)
	IC50	309.8008
	CC50	446.3594
	SI	788.1076
	Средний RMSE (AVG)	514.7560

ЧТО ПОВЛИЯЛО НА РЕЗУЛЬТАТ



Логарифмическая трансформация таргетов ($\log_{10}$)



Отбор Top-100 признаков по важности (SelectFromModel на ExtraTrees)



Комбинация пяти различных алгоритмов для усиления сильных сторон моделей



5-fold CV для IC50 и CC50, StratifiedKFold для SI



Оптимизация гиперпараметров для каждой модели



ИСПОЛЬЗОВАННЫЕ МОДЕЛИ



ExtraTrees



CatBoost



XGBoost



GradientBoosting



LightGBM

МЕТОД ВАЛИДАЦИИ



5-fold CV (IC50, CC50)
StratifiedKFold (SI)

ПРЕОБРАЗОВАНИЕ ТАРГЕТОВ



$\log_{10}$

МЕТА-МОДЕЛЬ



RidgeCV



Применение комбинации пяти моделей, отбора информативных признаков и кросс-валидации позволило построить устойчивый pipeline предсказания биологической активности молекул.